

Validação e extensão do specmine para dados Raman

Processamento Espectral e Otimização de Pipelines

Espectroscopia Raman

Técnica analítica ótica baseada no **espalhamento inelástico da luz**.

- **Impressão Digital Molecular:** Cada molécula altera a frequência da luz de forma única, revelando as ligações químicas.
- **O Grande Desafio:** O sinal Raman útil é **extremamente raro e inerentemente fraco**.
- Apenas 1 em cada 10 milhões de fótons sofre este espalhamento, tornando a detecção muito difícil em amostras diluídas.



Especificidade Química Única

SERS: Signal Amplification

Para superar a fraqueza do sinal Raman, as moléculas são colocadas em **locais específicos** de superfícies metálicas nanoestruturadas.



Ressonância Plasmónica

O laser excita eletrões de condução em pontos precisos de Ouro ou Prata.



Campos Eletromagnéticos

Campos localizados gigantesco
criam áreas amplificadas
chamadas de **hotspots**.



Ganho Exponencial

As moléculas nestes locais
sofrem aumentos de sinal de **10⁴**
a **10¹⁴** vezes.

O Paradoxo da Sensibilidade

Como o SERS é capaz de detetar analitos em traços, também **amplifica todo o ruído circundante e a interferência de fundo**. O sinal bruto torna-se caótico.

❗ Ruído e Artefactos

- **Raios Cósmicos:** Picos falsos (spikes) gigantes nos detetores.
- **Desvios de Baseline:** Distorções causadas por fluorescência.

⚠ Limites Físicos

- Dependência de Hotspots: O ganho cai se estiver fora do gap.
- Reprodutibilidade: Sinais variáveis entre chips diferentes.

Pipeline de Processamento Obrigatória



1. Despiking

Remoção de artefactos ambientais e raios cósmicos.



2. Baseline Correction

Subtração matemática do desvio de fluorescência.



3. Normalization

Uniformização de escalas entre diferentes amostras.



4. Machine Learning

Treino de modelos preditivos sobre dados limpos.

Ecossistema specmine e Motivação

O Pacote specmine

Desenvolvido pelo **CEB (Centro de Engenharia Biológica)** da Universidade do Minho. Criado para simplificar a análise metabolómica.

O Grande Desafio

Construir uma pipeline Raman exige **conhecimentos matemáticos e de programação muito avançados**, criando barreiras para investigadores.

Objetivo do Projeto

Como o specmine estava desatualizado para os requisitos Raman modernos, o meu trabalho focou-se em:

- **Simplificação:** Tornar o uso de algoritmos complexos mais intuitivo.
- **Implementação:** Identificar falhas e integrar toda a pipeline Raman no ambiente specmine.

Extensão do specmine: Implementações Principais


Etapa	Limitação no specmine	Novo Contributo e Implementação
Despiking	Picos de fluorescência não detetados	dataset_despike(): Algoritmo Modified Z-Score automático.
Linha de Base	ALS limitado / Baixa performance	airPLS_fast_dataset() e DRPLS(): Métodos de matriz esparsa.
Normalização	Adaptabilidade limitada	raman_norm(): Funções de Min-Max e Vetorial L2 .
Machine Learning	Sem suporte para Deep Learning	Integração de Random Forest (RF) , SVM e CNN 1D .
Visualização	Não otimizada para Raman	raman_radar_plot(): Projeções polares e visualização 3D do espectro.

Análise de Espetros Raman: Impacto do Pré-processamento

Visualização Estatística

Comparação entre o sinal bruto (Raw) e o sinal final após o pré-processamento.

- ✓ Remoção da fluorescência (airPLS).
- ✓ Eliminação de artefatos e raios cósmicos.
- ✓ Padronização da variabilidade entre amostras.
- ✓ Destaque dos picos moleculares característicos.



Resultados: Modelo Random Forest (RF c/L2)



	mtry	Accuracy	Kappa
1	2	0.90	0.8444444
2	61	0.90	0.8444444
3	1867	0.86	0.7918129



	mtry	Accuracy	Kappa
1	2	0.9033702	0.8497937
2	139	0.8886161	0.8264672
3	276	0.8902690	0.8288818



	mtry	Accuracy	Kappa
1	2	0.9914286	0.9892857
2	41	0.9920000	0.9900000
3	851	0.9760000	0.9700000

A normalização L2 ajuda a estabilizar o Random Forest, mas o fator decisivo continua a ser a separabilidade intrínseca dos dados. Em todos os datasets, mtry baixo (≈ 2) gera o melhor desempenho, mostrando a elevada redundância dos espectros. Os três conjuntos apresentam dificuldades diferentes: o Dataset 3 é o mais simples, com classes muito bem separadas e resultados quase perfeitos; o Dataset 2 mostra boa qualidade e fronteiras mais definidas; e o Dataset 1 é o mais complexo, com maior sobreposição entre classes e queda de desempenho quando se usam demasiadas variáveis por split. No geral, a estrutura interna dos dados é o que realmente dita a performance do modelo.

Resultados: Modelo Support Vector Machine (SVM c/L2)



	sigma	C	Accuracy	Kappa
1	0.003936773	0.25	0.8853905	0.8220753
2	0.003936773	0.50	0.8935337	0.8347972
3	0.003936773	1.00	0.8951195	0.8368537






	sigma	C	Accuracy	Kappa
1	0.0003040159	0.25	0.3633333	0.0000000
2	0.0003040159	0.50	0.7933333	0.6856209
3	0.0003040159	1.00	0.9000000	0.8444444



	sigma	C	Accuracy	Kappa
1	0.0006657238	0.25	0.8354286	0.7942857
2	0.0006657238	0.50	0.9737143	0.9671429
3	0.0006657238	1.00	0.9954286	0.9942857

Nos conjuntos mais difíceis, o modelo só atinge desempenhos elevados com valores altos de C, evidenciando a necessidade de uma margem mais rígida para lidar com a forte sobreposição espectral. Nos datasets de melhor qualidade, o SVM aproxima-se de classificações quase perfeitas, mostrando que a normalização L2 realça diferenças estruturais quando as classes já são naturalmente distintas. No geral, os resultados confirmam que o SVM é eficaz, mas sensível ao tuning de C e à qualidade dos dados, repetindo o padrão observado no Random Forest: o Dataset 3 é o mais simples, seguido do Dataset 2, enquanto o Dataset 1 apresenta maior complexidade e menor separabilidade.

Resultados: Rede Neuronal Convolutacional (CNN1D)



A CNN apresenta um comportamento estável e sem sinais de overfitting, mas o seu desempenho final depende sobretudo da separabilidade intrínseca dos dados. Nos datasets mais difíceis, a rede melhora ao longo das épocas, mas não atinge o desempenho dos modelos clássicos, refletindo maior sobreposição entre classes e padrões menos definidos. Nos datasets de melhor qualidade, a CNN aproxima-se de classificações quase perfeitas, mostrando que consegue extrair padrões muito eficazes quando as diferenças espectrais são claras. No entanto, **no Dataset 3 a rede não conseguiu distinguir as classes**, evidenciando que a estrutura interna dos dados continua a ser o fator determinante para o seu desempenho.

Visualização: raman_radar_plot()



Projeção Polar 3D


A função converte o espectro linear convencional numa projeção polar, mapeando os *wavenumbers* para ângulos e a intensidade para o raio.






Assinatura de Classe

Cria uma "impressão digital" geométrica única para cada amostra, facilitando a distinção visual imediata entre grupos (ex: Controlo vs. Patológico).

Impacto Analítico: Ao projetar a média espectral em 3D, o utilizador consegue identificar simetrias e variações de sinal que passariam despercebidas num gráfico de linhas 2D tradicional.



Resultados: Extração de Padrões Visuais via CNN 2D



Nos dois primeiros datasets, o **CNN1D** apresentou resultados superiores, conseguindo capturar padrões espectrais finos e contínuos, característicos de dados 1D. A arquitetura 1D mostrou maior estabilidade, melhor generalização e menor taxa de erro por classe, enquanto o **CNN2D** revelou maior dificuldade em distinguir classes mais semelhantes, apresentando matrizes de confusão mais dispersas e métricas globais inferiores.

Contudo, no último dataset, verificou-se o comportamento inverso: o CNN2D conseguiu distinguir as classes de forma mais eficaz, enquanto o CNN1D apresentou maior confusão entre classes específicas. Isto indica que, neste caso, a transformação dos dados para formato 2D criou padrões espaciais suficientemente distintos para que a arquitetura 2D os explorasse de forma vantajosa. Assim, o CNN2D beneficiou de relações estruturais adicionais introduzidas pela representação bidimensional, conseguindo separar classes que o CNN1D não conseguiu discriminar tão bem.

Melhorias Possíveis



Equilíbrio das Classes

Ajustar os modelos para balancear as classes através de técnicas de *oversampling* ou ajuste de pesos, mitigando o enviesamento em dados clínicos.



Expansão Amostral

Incrementar o número de amostras através da seleção de *datasets* de maior escala, fortalecendo a robustez estatística dos resultados obtidos.



Otimização do CNN

Refinar a regularização e o *dropout*. Otimizar o número de épocas e implementar mecanismos de *early stopping* para evitar o sobreajustamento.



Carregamento de Dados

Aprimorar a performance técnica no carregamento de ficheiros e dados brutos, garantindo uma maior fluidez no arranque da *pipeline* de análise. Facilitando a utilização ao utilizador.

i Estas melhorias visam consolidar o **specmine** como uma plataforma líder no processamento automatizado de dados Raman.